NIM: 2702234636

Video Penjelasan: https://drive.google.com/file/d/1p95qemXSXYTf0JTYwCSQ6fYk-c-

1X1Yq/view?usp=sharing

Essay:

Testing apa saja yang perlu Anda lakukan untuk memastikan bahwa model prediksi tingkat obesitas ini akan berjalan dengan baik dan tidak akan mengalami gangguan ketika berada di sistem produksi? Jelaskan rencana pengujian Anda secara sistematis dan Sertakan contoh berdasarkan fitur dalam dataset obesitas, seperti bagaimana jika nilai pada Age, Weight, SMOKE, atau MTRANS dimanipulasi.

Proses ini diawali dengan **pengujian unit**, yang merupakan fondasi di mana setiap fungsi individual kode diuji secara terisolasi. Pada tahap ini, kita akan memverifikasi secara spesifik bahwa fungsi kalkulasi BMI di frontend tidak hanya menghasilkan nilai yang benar untuk input tinggi dan berat yang wajar, tetapi juga mampu menangani kasus ekstrem seperti input tinggi nol tanpa menyebabkan aplikasi crash. Demikian pula di backend, setiap logika transformasi data akan diuji, misalnya memastikan input string seperti "Male" pada fitur Gender secara konsisten dipetakan ke nilai numerik 1 dan input "No" pada fitur SMOKE dipetakan ke 0, termasuk validasi terhadap inkonsistensi penulisan seperti huruf besar atau kecil.

Setelah setiap komponen terbukti andal, pengujian berlanjut ke **level integrasi**, di mana fokusnya adalah memastikan komunikasi antar komponen, terutama antara frontend Streamlit dan backend FastAPI, berjalan tanpa hambatan. Pengujian ini akan mensimulasikan pengiriman data lengkap dari formulir frontend ke API backend, memvalidasi bahwa backend dapat menerima dan memproses payload JSON dengan benar, menjalankan model, dan mengembalikan respons yang valid. Keberhasilan pada tahap ini diukur dari kemampuan frontend untuk menerima kembali respons tersebut dan menampilkannya dengan benar kepada pengguna. Ini kemudian divalidasi lebih lanjut melalui **pengujian ujung ke ujung (E2E)**, yang mensimulasikan seluruh alur kerja pengguna secara otomatis menggunakan alat seperti Selenium atau Playwright. Skrip pengujian akan membuka aplikasi, mengisi formulir dengan profil pengguna yang telah ditentukan, menekan tombol prediksi, dan memastikan hasil akhir yang ditampilkan di layar sesuai dengan yang diharapkan.

Aspek terakhir dan yang paling kritikal adalah **pengujian ketahanan (robustness testing)**, di mana kita secara sengaja "menyerang" sistem dengan data yang dimanipulasi untuk menguji batas kemampuannya. Ini lebih dari sekadar menguji nilai di luar batas wajar untuk Age dan Weight; ini juga mencakup pengiriman tipe data yang salah (misalnya, teks di kolom usia) untuk memastikan backend menolaknya dengan pesan error yang sesuai (seperti error 422 Unprocessable Entity), bukan berhenti bekerja. Selain itu, pengujian ini akan mencoba mengirimkan nilai string yang tidak terduga untuk fitur kategorikal seperti MTRANS (misalnya, "Pesawat") untuk memverifikasi bahwa sistem memiliki logika penanganan kesalahan yang dapat memberikan respons terkendali dan informatif, sehingga membuktikan bahwa aplikasi tidak hanya akurat tetapi juga stabil dan aman saat dihadapkan pada input dunia nyata yang tidak dapat diprediksi

NIM: 2702234636

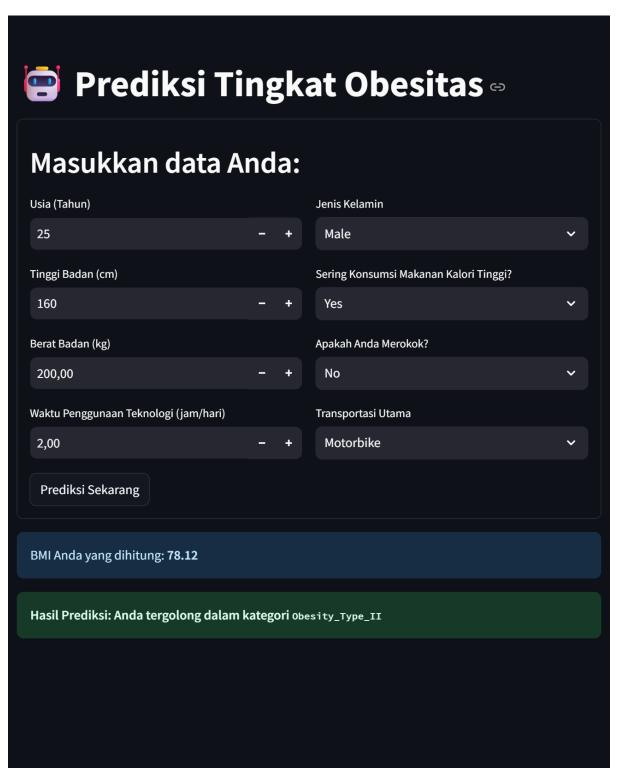
Anda telah berhasil membangun dan mendistribusikan model machine learning ke dalam sistem informasi klinik untuk memprediksi tingkat obesitas seseorang berdasarkan data gaya hidup. Setelah berjalan selama beberapa bulan, Anda mulai memperhatikan bahwa hasil prediksi mulai menunjukkan penurunan akurasi. Jelaskan apa yang dimaksud dengan model drift dan data drift dalam konteks sistem prediksi obesitas ini?

Penurunan akurasi model setelah beberapa bulan di sistem produksi seringkali disebabkan oleh fenomena yang dikenal sebagai *model drift* atau *data drift*. **Model drift**, atau *concept drift*, terjadi ketika hubungan fundamental antara fitur dan hasil di dunia nyata berubah, sehingga "aturan" yang telah dipelajari model menjadi usang. Dalam konteks ini, misalnya, jika sebuah kampanye kesehatan baru membuat bersepeda menjadi populer di semua kalangan, maka fitur MTRANS yang sebelumnya mungkin berkorelasi kuat dengan berat badan normal, kini kehilangan kekuatan prediktifnya. Aturan dalam model tidak lagi mencerminkan realitas yang baru.

Di sisi lain, **data drift**, atau *feature drift*, terjadi ketika distribusi statistik dari data input baru berbeda secara signifikan dari data yang digunakan saat pelatihan, meskipun hubungan dasarnya tetap sama. Sebagai contoh, jika klinik pada awalnya melayani populasi mahasiswa dengan rata-rata Age 22 tahun, namun kemudian memperluas layanan ke area perkantoran dengan rata-rata Age 40 tahun, maka model akan menerima data dengan distribusi usia yang sangat berbeda. Meskipun hubungan antara usia dan obesitas tetap valid, performa model akan menurun karena ia tidak "berpengalaman" dengan demografi data yang baru ini, sehingga menyebabkan penurunan akurasi secara keseluruhan.

NIM: 2702234636

Test Case 1:



NIM: 2702234636

Test Case 2:

